

Projet mathématiques-informatique, S6, Parcours Math-Info

Enseignante : Raquel URENA
Email: raquel.urena@univ-amu.fr

March 27, 2025

Projet : Implémentation et Explication d'un Modèle de Régression Logistique en Python

Objectif

Vous devez implémenter **depuis zéro** un modèle de régression logistique pour un problème de classification binaire. **Aucune bibliothèque de machine learning ne doit être utilisée** (pas de `scikit-learn`, `tensorflow`, etc.). Vous devez :

- coder manuellement l'algorithme d'entraînement (descente de gradient),
- tester le modèle sur un cas réel simple,
- évaluer sa performance,
- interpréter les coefficients du modèle pour identifier les variables les plus influentes.

Introduction à la Régression Logistique

La régression logistique est un modèle de classification linéaire. Elle prédit la probabilité d'appartenance à une classe à l'aide de la fonction sigmoïde :

$$\hat{y} = \sigma(\mathbf{w}^T \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}}$$

où $\mathbf{x}$ est le vecteur de caractéristiques, $\mathbf{w}$ le vecteur de poids, b le biais, et $\hat{y}$ la probabilité prédite. La fonction de perte utilisée est l'entropie croisée (log-loss) :

$$\mathcal{L} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

L'objectif est de minimiser cette fonction via une descente de gradient.

Étapes du Projet

1. Création ou chargement du jeu de données :

- Vous pouvez générer un jeu de données artificiel (avec quelques variables continues/catégorielles), ou utiliser un petit jeu public (ex : diabète, admissions, etc.)

2. Prétraitement des données :

- Normalisation des variables, encodage si besoin, séparation en X et y .

3. Implémentation du modèle :

- Fonction sigmoïde
- Fonction de coût (log-loss)
- Descente de gradient pour mise à jour de $\mathbf{w}$ et b
- Prédiction, évaluation (précision, matrice de confusion)

4. Analyse des coefficients :

- Les poids $\mathbf{w}$ reflètent l'influence de chaque variable (en module).
- On peut les afficher graphiquement pour mieux interpréter le modèle.

Étude de Cas : Prédiction de l'admission universitaire

Supposons un jeu de données contenant les notes de tests, le taux de réussite au lycée, et la participation aux activités extra-scolaires pour prédire si une personne a été admise dans une université.

- Variables :
 - `Note_test` : score sur 100
 - `Taux_lycée` : pourcentage de réussite au lycée
 - `Extrasco` : binaire (1 = participation, 0 = non)
- Cible :
 - `Admission` : 1 si admis, 0 sinon

Visualisation de l'importance des variables

Une fois l'entraînement terminé, affichez graphiquement les poids pour interpréter quelles variables influencent le plus la prédiction.




Figure 1: Importance relative des variables (valeurs fictives)

Évaluation du Modèle

Évaluez la performance sur un ensemble de test :

- Matrice de confusion
- Précision, rappel, F1-score
- Optionnel : courbe ROC et AUC

Livrable

Un notebook Jupyter complet comprenant :

- Code commenté (modèle, entraînement, évaluation)
- Graphiques d'interprétation
- Une explication du rôle de chaque variable
- Une réflexion sur les limites du modèle

Réunions et Encadrement

Une réunion initiale de cadrage sera organisée, puis des suivis à la demande par email ou visioconférence.

Références

- Wikipedia. *Régression logistique*, https://fr.wikipedia.org/wiki/Régression_logistique
- Sebastian Raschka. *Logistic Regression*
- Cormen et al. *Introduction à l'algorithmique*, Pearson, 2004.